

Методологический отчёт — Атлас 2.0

1. Постановка

Исходный атлас выделяет семь типов муниципальных территорий по динамике безналичных расходов. Модернизация сохраняет оригинальную типологию, визуальный язык и интерактивную географию, добавляя анализ неоднозначности типов и дополнительный независимый эксперимент PULSE.

2. Данные и единицы наблюдения

В исходном наборе потребления 303 126 строк за январь 2023 — декабрь 2024; 2 190 территорий, 2 016 с полным 24-месячным рядом. Есть пять предметных категорий и «Все категории». Категории не исчерпывают сумму «Все категории». Дополнительно есть `market_access` и 5 942 364 пар транспортных расстояний.

В загруженном файле [data_01_socio_economic_102_v20260313.xlsx](#) есть региональные социально-экономические показатели Росстата: столбцы `object_name`, `object_level`, `object_oktmo`, `year`, `indicator_value`, `indicator_unit`. Проверенный пример — показатель Y477110461 «Численность населения» на уровне Регион, единица — тысячи человек. Этот файл не является валидированным муниципальным регистром населения, и подменять им численность МО нельзя. Все доли типов — по количеству МО, а не по численности жителей. Для population-weighted результата нужен отдельный муниципальный источник и проверенная стыковка по ОКТМО/границам.

3. Оригинальная кластеризация

[src/features.py](#), [src/networks.py](#), [src/clustering.py](#), [src/icvi.py](#), [src/run_clusters.py](#) — оригинальный код из [code.zip](#). Для точной пересборки необходимы дополнительные подготовленные массивы и справочник МО, на которые ссылается исходный [src/build_dataset.py](#). Без них нельзя честно заявлять полную воспроизводимость исходных семи типов.

4. Дополнительное определение структурного сдвига

Для каждого МО и месяца вычисляются доли пяти категорий в общих расходах. Из долей вычитается медиана по всем МО в этом месяце. Локальная сила изменения — евклидова норма разности между текущим вектором и средним за предыдущие три месяца. Кандидат: верхний дециль по месяцу. Устойчивое событие: сила изменения в следующем месяце не ниже 60-го перцентиля. Важно: для ретроспективной маркировки устойчивости используется следующий месяц, поэтому эта метка недоступна в момент самого сдвига.

5. Пространственная ассоциация

Для каждого МО определяются k ближайших соседей по автомобильным расстояниям. При $k=5$ условный риск устойчивого события — 13,49% после события у соседа против 5,25% без него, $RR=2,57$. При $k=1/3/10/20$ $RR \approx 2,95/2,51/2,52/2,62$. Placebo переставляет сетевую экспозицию внутри месяца. Это свидетельствует об ассоциации, но не доказывает причинное влияние: возможны общие региональные факторы, пространственная автокорреляция и селекция соседей.

6. Прогноз

Цель: устойчивое событие в $t+1$. Модель: логистическая регрессия с признаками собственной истории, структуры расходов и `market_access`; экспериментальная версия добавляет долю ближайших соседей с текущим устойчивым событием. Expanding-window backtest, PR-AUC и ROC-AUC. History baseline: PR-AUC 0,2556, ROC-AUC 0,8239, Brier 0,1599. Сеть: PR-AUC 0,2632, ROC-AUC 0,8299, Brier 0,1559. Прирост PR-AUC $\approx 3\%$.

Критическое ограничение: сетевой признак «устойчивое событие в t » использует подтверждение события в $t+1$. Это утечка будущей информации в реальном времени. Поэтому приведённые результаты — ретроспективный исследовательский ориентир, не доказательство готовой оперативной системы раннего предупреждения. Перед конкурсной заявкой необходимо переобучить прогноз на каузально доступном candidate shift в t и повторить temporal backtest. Не следует называть текущие цифры продакшн-качеством прогноза.

7. Сравнение методов обнаружения точек изменений

Исходный атлас исследует устойчивость типов и их переходы; PULSE использует robust change score. Формальное сравнение CUSUM, PELT, Bayesian online change-point detection по единой размеченной выборке в переданных артефактах отсутствует. Числа для этих методов не выдумываются. Это обязательная незакрытая часть для полной конкурсной заявки.

8. Примеры

В [results/structural_shift_events.csv](#) содержатся реальные идентификаторы МО, даты и категории-драйверы. Для перевода идентификаторов в названия нужен словарь МО и контроль версии справочника. Региональные статистики не приписываются конкретному МО.

9. Архитектура

СберИндекс CSV → контроль полноты → доли категорий → семитипная типология оригинала → структурные изменения → транспортные соседи → ретроспективная валидация → интерактивный атлас → GitHub Pages.

10. Воспроизводимость и публикация

Код и параметры в репозитории; сайт автономен. Точный оригинальный расчет требует отсутствующих внешних файлов; дополнительные результаты включены как зафиксированные CSV. Публикация на GitHub требует авторизации пользователя.

Приложение А. Сравнение моделей (ретроспективный эксперимент)

Модель	PR-AUC	ROC-AUC	Brier
История + контекст	0.256	0.824	0.160
История + контекст + сеть	0.263	0.830	0.156

Примечание: метрики не следует интерпретировать как валидированный оперативный прогноз из-за использования будущей информации при формировании сетевого признака.